

최예지

Ye Ji, Choi



Language

PythonMySQL

C, C#JavaScript

Tool

UnityMatLab

PlantSimulation

AI/ML

PytorchRL

LLMOpenCV

소개

도전을 성장의 동력으로 삼아, 미래의 기술을 현실로 만드는 엔지니어
끝까지 방법을 탐색하고, 실패에서도 다음 단계의 가능성을 찾아내는 엔지니어

학력사항

2024.09 - 2026.08	서울과학기술대학교 인공지능응용학과	졸업 예정
2021.03 - 2024.08	서울과학기술대학교 인공지능응용학과	졸업

어학

2025.09.20	TOEIC Speaking Test	Advanced Low (160)
------------	---------------------	--------------------

자격증

2025.11.13	식스시그마 그린벨트
2025.07.11	빅데이터분석기사
2025.03.13	운전면허(2종 보통)
2024.09.10	정보처리기사

경험

2026.01 -	University of Toronto LG AI Lab Personalized VLM
2026.01 - 2026.06	캐나다 토론토대 AI 융합 교육프로그램
2025.09 - 2025.12	[시뮬레이션] 조교
2025.07 - 2025.08	LG Aimers 7기
2025.03 - 2025.06	[데이터사이언스] 조교
2023.07 - 2024.12	서울런 멘토링
2023.01 (1개월)	UNLV(University of Nevada, Las Vegas) 단기파견
2022.09 - 2022.12	인공지능응용전공 튜터링, 튜터
2021.03 - 2022.12	서울과학기술대학교 학생복지위원회

저널

2026.02.09	User-Friendly Assembly Line Optimization: A Hierarchical Approach Combining Simulation-Evaluated Heuristics and Reinforcement Learning (최예지, 김병수)	Journal of Computational Design and Engineering
2025.12.24	Integrating simulation and deep reinforcement learning for multi-objective assembly line design (최예지, 김병수)	Journal of Intelligent Manufacturing
2025.03	딥강화학습과 시뮬레이션을 활용한 제조 레이아웃의 물리적 배치 최적화 (최예지, 김민성, 김병수)	한국정밀공학회지

최예지

Ye Ji, Choi



Language

PythonMySQL

C, C#JavaScript

Tool

UnityMatLab

PlantSimulation

AI/ML

PytorchRL

LLMOpenCV

국내 학회

2024.08	실시간 디지털 트윈 모델링을 통한 작업자 충돌 감지 및 예측 시스템에 관한 연구 (홍민주, 김예찬, 최예지)	한국 CDE학회 (구두 발표)
2024.08	강화학습을 활용한 제조 레이아웃의 물리 배치 최적화 (최예지, 김민성, 김병수)	한국 CDE학회 (구두 발표)
2023.06	강화학습을 활용한 최소 무장 할당 문제에 관한 연구 (최예지, 김병수)	대한전자공학회 (포스터)
2022.11	Phase Lag Entropy를 이용한 알츠하이머병의 뇌 연결성 연구 (최예지, 김연수, 박진석)	대한전자공학회 (포스터)
2022.02	BCI를 위한 동작 상상 뇌파 분류에 관한 연구 (최예지, 김광일, 김예찬) (DBpia Top 5%)	한국통신학회 (구두 발표)

프로젝트


• 개인 프로젝트 •		
DEVS 환경에서의 강화학습 기반 병목 지점(GBP) 최적화		
DEVS 기반 다중 에이전트 경로 최적화		
• 팀 프로젝트 •		
2023.09 - 2024.06	Unity 환경에서의 RGB-D 카메라 기반 충돌 예측 및 경고 시스템 설계	
2022.09 - 2022.12	키오스크 VR 데이터를 활용한 MCI(경도 인지 장애) 테스트 점수 예측 모델 개발	
2022.09 - 2022.12	Transfer Learning 기반 개인화 TTS (Text-To-Speech) 모델 구현	
2022.09 - 2022.12	딥강화학습 기반 사이버 침투 시나리오 최적화 시스템 설계	
2022.02 - 2022.06	YOLO를 활용한 교통표지판 분류	

Don't Be Fooled: Adversarial Image Synthesis for Personalized VLMs

연구 배경

- Personalized VLM이 target과 유사 target 구분하지 못하는 한계점 존재
- 사용자별 VLM retraining은 연산 비용이 과도하여, 데이터 중심의 대안 필요
- 핵심 난제는 Hard Negative를 변별하는 능력이며, 이를 위한 양질의 Hard Negative 데이터 확보가 관건

프레임워크



- Image 기반 구조적 속성 표현: target의 정체성 보존을 위해 입력 이미지에서의 target 속성을 Invariant와 Variant로 분리
- Alice-Bob 적대적 생성 루프
 - Alice(출제자): LLM Optimizer가 프롬프트 생성
→ Diffusion 모델로 Positive-Hard Negative-Easy Negative 합성
 - Bob(응답자): Personalized VLM이 인식 문제 수행
 - 보상 설계: Bob이 틀릴수록(난도가 높을수록) Alice에 positive reward 부여 → 점진적으로 더 어려운 Hard Negative 생성 유도
 - Verifier 보상: 생성 이미지가 의도한 카테고리 and 일치하는지 검증
- 효율적 데이터 전략: Positive-Easy Negative는 실제 데이터, Hard Negative만 합성하여 비용 최소화

주요 결과

Hard Negative Image Generation Example



Positive · Easy Negative · Hard Negative Sample Example



Hard Negative Mining : Method Comparison

Method	Variant Set (10 images)	YoLLaVA (ACC ↑)	MyVLM (ACC ↑)
Baseline 1 (Random)	Random Neg 10	0.656	0.783
Baseline 2 (Searched)	Searched Neg 10	0.804	0.738
👉 Ours (Generated)	Generated HN 10	0.837	0.805

Detection Performance : YoLLaVA, MyVLM

iter	TPR ↑	FPR ↓	Acc ↑	iter	TPR ↑	FPR ↓	Acc ↓
iter0	0.867	0.189	0.828	iter0	0.577	0.166	0.776
iter1	0.859	0.169	0.843	iter1	0.596	0.147	0.796
iter2	0.868	0.178	0.837	iter2	0.520	0.106	0.805
iter3	0.856	0.160	0.848	iter3	0.603	0.139	0.803

- ✓ 반복적 적대적 합성 프레임워크 제안: 사용자별 VLM 재학습 없이, 정체성을 보존하면서 Iteration마다 점점 더 어려워지는 Hard Negative를 생성하는 데이터 중심(data-centric) 접근 구현
- ✓ 두 벤치마크 모두 최고 정확도: 생성 Hard Negative(Ours)가 YoLLaVA 0.837-MyVLM 0.805로 Random(0.656-0.783)-Searched(0.804-0.738) 베이스라인을 모두 상회
- ✓ 반복 학습에 따른 성능 향상: Iteration 누적에 따라 정확도 상승·오탐률(FPR) 감소
- ✓ 무작위·검색 기반으로 Negative를 양적으로 확장하기보다 적대적 합성이 변별력 향상에 효과적


User-friendly assembly line optimization : A hierarchical approach combining simulation-evaluated heuristics and reinforcement learning

Master's Research II | 25.06 ~ 26.02 | DTLab

연구 배경

- 기존 조립 라인 최적화 연구는 현장 실무자의 요구사항을 정형화된 데이터로 변환하는 과정 없이 진행되어, 실제 운영 데이터와의 괴리로 현장 적용성이 저하되는 한계 존재
- 라인 밸런싱, 논리적 시스템 구성, 물리적 레이아웃 설계가 독립적으로 처리되어 단계 간 데이터 연계가 부재하고, 각 단계의 산출 데이터가 후행 단계에 일관되게 전달되지 못하는 문제 존재
- 이를 극복하고자 비정형 자연어 요구사항을 LLM이 정량적 변수로 자동 변환하여 후행 최적화 알고리즘에 직접 공급하는 엔드투엔드 데이터 파이프라인 프레임워크 제안


프레임워크



- 1) ASALBP-based Task Allocation**
조립 라인의 기본 정보를 바탕으로 MILP를 적용하여 공정별로 적절한 작업을 배분하는 ASALBP 솔루션 도출
- 2) Interpreting User Inputs**
현장 실무자가 요구하는 다양한 제약 조건과 최적화 목적을 LoRA로 파인튜닝된 LLM이 해석하여, 후행 알고리즘이 연산할 수 있는 정량적인 목적 함수와 제약 변수로 자동 변환
- 3) Logical Optimization**
유전 알고리즘과 Plant Simulation을 연동하여 전체 시스템 구성, 자원 할당, 제조 셀의 종류 등 조립 라인의 전반적인 논리적 구조를 2단계에서 받은 목적 함수에 따라 최적화함.
- 4) Physical Optimization**
 - 4-1) 앞서 결정된 논리적 구조를 바탕으로 IQN 알고리즘을 적용해 최종 물리적 배치 결정
 - 4-2) 피드백 루프: 유효한 물리적 배치가 없는 경우, 제약 조건에 해당 구조를 추가하여 다시 논리적 구조 단계로 돌아감.

주요 결과

ASALBP-based Task Allocation 결과



Workstation	# of Tasks	Assigned Tasks	Cycle Time	# of Workers	Is Cell
1	2	1,2	0.5	[0,1]	TRUE
2	3	5,6,7	0,4,3	[0,1,1]	TRUE
3	2	8,12	5,1	[1,1]	TRUE
4	1	10	4	[2]	FALSE
5	1	9	5	[1]	FALSE
6	1	11	4	[1]	FALSE
7	1	13	6	[1]	FALSE

Interpreting User Inputs & Logical Optimization 결과


- 사용자의 입력 내용에 따라 동일한 ASALBP 해라도 다른 논리적 해가 도출됨을 확인

[User Input]



"Maximize the production rate with five available workers and allow up to ten conveyors."

[Scenario 1]



[Configuration]

Hyperparameters				Constraints		KPI	
# of Conveyors	Cell Type	Source Interval	Conveyor Speed	Converter Speed	Workers	Sum of Conveyors	Throughput
[1,1,1,0,2,0,2,0]	[3,1,1]	400	1	1	5	7	200

User-friendly assembly line optimization : A hierarchical approach combining simulation-evaluated heuristics and reinforcement learning

Master's Research II | 25.06 ~ 26.02 | DTLab




[User Input]



"Set the weight of production rate to 0.2, and the weights for the number of workers and conveyors to 0.4 each. Up to ten workers and ten conveyors can be added."


[Scenario 2]



[Configuration]

Hyperparameters					Constraints		KPI
# of Conveyors	Cell Type	Source Interval	Conveyor Speed	Converter Speed	Workers	Sum of Conveyors	Throughput
[1,1,1,0,2,0,2,0]	[3,1,1]	400	1	1	5	7	200

Physical Optimization 결과



결론

- ✓ **엔드투엔드 데이터 파이프라인 설계:** 데이터 수집·변환·처리·공급을 단계별로 연계하여 비정형 요구사항부터 최적 레이아웃 도출까지 일관된 데이터 흐름을 구현하는 계층적 통합 프레임워크 개발
- ✓ **LLM 기반 사용자 최적화 연계:** 기존의 파편화된 설계 방식에서 벗어나, LLM을 활용해 현장 실무자의 자연어 요구사항을 정량적 변수로 변환하고 이를 후행 최적화 알고리즘과 직접 연계
- ✓ **다단계 데이터 처리 구조 구현:** 논리적 최적화 단계의 산출 데이터를 물리적 최적화 알고리즘에 직접 공급하는 구조를 설계하여, 단계 간 데이터 연계 누락 없이 강건한 최종 레이아웃을 도출함.
- ✓ **실행 가능성 및 강건성 입증:** 이산 사건 시뮬레이션을 통해 성능 지표를 평가한 결과, 논리적 설계와 물리적 제약 간의 충돌을 방지하며 기존 단일 목적 접근법 대비 현실적이고 실행 가능한 최적해를 산출함을 입증


Integrating simulation and deep reinforcement learning for multi objective assembly line design

Master's Research I | 24.06 ~ 25.12 | DTLab

연구 배경

- 제조 라인의 공간 효율성·흐름 안정성·자원 활용도 등 **다목적 KPI**를 **실시간으로 수집·처리**하여 의사결정에 활용하기 위한 데이터 파이프라인 설계 필요
- 전통적인 선형 프로그래밍이나 메타휴리스틱 알고리즘은 비선형적 제조 데이터의 복잡성을 파이프라인으로 처리하기 어려워 **실시간 데이터 기반 의사결정 지원에 한계** 존재


프레임워크



- 1) **Data Collection:** 공장 정보와 제조라인 정보 수집
- 2) **Simulation-Driven RL Training**
 - 2-1) 딥강화학습 에이전트에게 정보 전달 및 학습 시작
 - 2-2) 배치를 완료한 에피소드는 관련 정보를 **COM Interface**를 활용하여 **PlantSimulation**에 전달
 - 2-3) 제조라인 자동 배치 및 시뮬레이션 실행 후 **KPI**값을 받아와 에이전트에게 **Reward**로 전달
- 3) **Optimal Layout:** 최종 제조라인 구조 도출

주요 결과

- Scenario 1 최적화 전후 결과 비교
- Scenario 2 최적화 전후 결과 비교



- Scenario별 성능 비교

Index	Scenario 1		Scenario 2	
	AS-IS	TO-BE	AS-IS	TO-BE
Avg of blocking portion (%) ↓	5.76	4.15	8.15	3.47
Number of bottleneck parts ↓	512	417	584	416
Throughput per hour ↑	79	79	78	78

- ✓ 시간당 처리량은 유지하면서도, **주요 병목 공정의 가동률을 Scenario 1과 2에서 각각 1.81%, 4.31% 가량 하향 안정화**
- ✓ **전체 병목 부품 수를 Scenario 1과 2에서 각각 18.55%, 28.77% 줄임.**
- ✓ **COM Interface** 기반 실시간 데이터 파이프라인으로 **Plant Simulation**과 강화학습 에이전트를 연동하여 다목적 KPI 데이터를 수집·처리했으며, 정량적 지표들 통해 파이프라인의 신뢰성을 입증
- ✓ 실시간 제조 데이터를 수집·분석하여 라인 재구성 및 설비 투자 의사결정을 사전 검증하는 데이터 기반 의사결정 지원 시스템으로 확장 가능

Real-Time Manufacturing Safety System Using Digital Twin and AI




Capstone Design Project | 23.09 ~ 24.06 | DTLab

연구 배경


- 산업 현장 내 작업자와 지게차 간 부딪힘 사고 증가에 따른 산업재해 및 생산성 저하 문제
- 디지털 트윈 기반 실시간 작업 공간 모니터링 및 AI 기술을 활용한 충돌 예측 및 감지 기술의 필요성 대두

시스템 개요

- RGB-D 카메라와 Unity 플랫폼을 활용한 디지털 트윈 기반 AI를 활용한 실시간 제조 안전 모니터링 시스템 제안



시스템 흐름도



- 좌표 추출 및 디지털 트윈 모델링
 - RGB-D 카메라의 Color Image를 YOLOv5 모델에 적용하여 작업자의 좌표를 추출
 - 추출된 좌표에 해당하는 깊이 값을 Depth Image에서 얻어 (x, y, z) 좌표를 계산
 - 산출된 좌표를 Unity 캐릭터와 연동하여 작업자의 움직임을 가상 공간에서 실시간 재현
- 충돌 예측 알고리즘
 - TTC(Time-to-Collision) 알고리즘과 Cosine Similarity를 함께 적용
 - Cosine Similarity로 이동 방향을 판별하고, TTC를 계산하여 임계 값과 비교
 - 충돌 위험 발생 시 실시간 경고 신호 출력

주요 결과

- 디지털트윈 렌더링 시각화 결과



- 작업자 2명 디지털트윈 실시간 동기화 성공
- YOLO 활용: 초당 30프레임 이상의 객체 인식 속도 구현
- 디지털트윈 연동: Unity 환경 내 100msec 이내의 실시간 동기화 성공
- TTC 활용: 충돌 지점·시점 시각화 및 청각 경고 발생
- LiDAR, RADAR 대비 비용 효율적인 저가 장비 기반 시스템
- 다양한 공정 레이아웃 및 작업 시나리오에 맞춰 커스터마이징 가능한 유연성 확보

- 충돌 예측 시각화 결과

Scenario 1) If two workers are travelling in the same direction



Scenario 2) When two workers are travelling in different directions (moving away)



Scenario 3) Any case where neither of the above two cases apply.



강화학습을 활용한 최소 무장 할당 문제에 관한 연구



Undergraduate Research II | 23.05 ~ 23.07 | DTLab

연구 배경


- 무장 할당이란 표적의 전체 격추 확률을 최대화하도록 기준에 따라 무장을 표적에 적절하게 분배하는 행위를 의미함.
- 기존 트리 알고리즘은 무장 개수가 많아질수록 탐색 시간이 급격히 증가하여 실시간 현장 적용에 한계 존재
- 이를 보완하기 위해 Q-Learning 알고리즘을 적용하여 효율적인 최적해 탐색 방법 제안

프레임워크



시나리오


- 공격 범위가 다른 3개의 무장을 이용해 가장 빨리 모든 부대의 전투력을 0으로 만드는 조합을 찾는 시나리오
- 각 무장 별 공격 범위 시각화 & 적 부대 피해량




	적 부대 1 감소량	적 부대 2 감소량	적 부대 3 감소량
무장 A	20% (적 전투력 $\geq 75\%$)	0% (적 전투력 $\geq 75\%$)	0% (적 전투력 $\geq 75\%$)
	24% (75% > 적 전투력 $\geq 50\%$)	0% (75% > 적 전투력 $\geq 50\%$)	0% (75% > 적 전투력 $\geq 50\%$)
	28% (50% > 적 전투력)	0% (50% > 적 전투력)	0% (50% > 적 전투력)
무장 B	10% (적 전투력 $\geq 75\%$)	20% (적 전투력 $\geq 75\%$)	0% (적 전투력 $\geq 75\%$)
	12% (75% > 적 전투력 $\geq 50\%$)	24% (75% > 적 전투력 $\geq 50\%$)	0% (75% > 적 전투력 $\geq 50\%$)
	14% (50% > 적 전투력)	28% (50% > 적 전투력)	0% (50% > 적 전투력)
무장 C	5% (적 전투력 $\geq 75\%$)	5% (적 전투력 $\geq 75\%$)	20% (적 전투력 $\geq 75\%$)
	6% (75% > 적 전투력 $\geq 50\%$)	6% (75% > 적 전투력 $\geq 50\%$)	24% (75% > 적 전투력 $\geq 50\%$)
	7% (50% > 적 전투력)	7% (50% > 적 전투력)	28% (50% > 적 전투력)

주요 결과

- Q Learning 적용 시 수렴 과정



- Full Search 방식의 Tree Algorithm 적용 시 수렴 과정



- ✓ Q-Learning 학습 결과, 최소 무장 할당 수는 10이었으며 약 50번의 학습만으로도 최소 무장 할당 수인 10으로 수렴하고 있는 모습 확인 가능
- ✓ 트리 알고리즘이 Full-Search 탐색 방법을 택한다면, 해당 무장 할당 시나리오에서는 $3 + 3^2 + 3^3 + \dots + 3^9$ 번, 즉, 32925번 탐색한 후에 최소 무장 할당 수에 도달함

Phase Lag Entropy를 이용한 알츠하이머병의 뇌 연결성 연구




Undergraduate Research I | 22.07 ~ 22.11 | BrAIIn Lab

연구 배경

- 알츠하이머병(AD)은 기억력, 사고력, 행동 문제를 일으키는 치매의 가장 흔한 형태
- 고령 인구 증가에 따라 환자 수가 기하급수적으로 늘어날 것으로 예상되며, 이를 해결하기 위해 뇌파(EEG)와 AD를 연관 짓는 연구 꾸준히 진행 중
- AD는 일반적으로 뇌의 비정상적인 기능적 연결성과 관련이 있다는 점에 착안하여 연구 시작


프레임워크



- 1) **Group Configuration**: HC 9명, MCI 8명, AD 5명 참가자 모집
- 2) **Feature Extraction**: 19채널 EEG 데이터를 측정하고 두 뇌파 채널 간 위상 관계의 일시적 패턴을 측정하는 지표인 PLE(Phase Lag Entropy)를 계산하여 각 그룹의 뇌 영역 간 기능적 연결성 조사
- 3) **Wilcoxon Rank Sum Test**: 대표적인 비모수 검정 방식인 윌콕슨 순위합 검정을 통해 세 그룹 간 PLE 평균값에 유의미한 차이가 있는지 통계적으로 검증
- 4) **머신러닝 분류**: 추출된 PLE 데이터를 기반으로 머신러닝 분류기인 SVM(Support Vector Machine) 모델을 학습시켜 세 그룹 간의 분류 가능성 테스트

주요 결과

- 19 x 19 PLE 측정에 의해 계산된 AD 그룹, HC 그룹, MCI 그룹의 히트맵 시각화 결과



Wilcoxon Rank Sum Test 결과

	HC vs AD	HC vs MCI	AD vs MCI
P-value	4.00E-36	0.0069	1.06E-36
h	1	1	1

SVM 학습 결과

	HC vs AD	HC vs MCI	AD vs MCI
Accuracy	0.7649	0.7578	0.7823
Mean Cross-Validation Accuracy	0.7684	0.7582	0.8022

- ✓ **그룹별 뇌 연결성 저하 확인**: AD 그룹의 PLE 값이 HC 그룹 대비 전반적으로 가장 낮게 나타났으며, 이는 뇌 영역 간의 결합 강도와 효율적인 정보 전달 기능이 크게 감소했음을 의미
- ✓ **두뇌 영역별 특징 도출**: HC 그룹은 후두엽의 PLE 값이 낮게 나타난 반면, MCI 그룹은 전두엽과 후두엽 사이의 PLE 값이 낮게 도출되는 등 위치적 차이 확인
- ✓ **통계적 유의성 입증**: 그룹간 통계 검증 결과, 모두 귀무가설이 기각되어 그룹 간 PLE 값에 유의미한 차이가 존재함 입증
- ✓ **치매 진단 가능성 시사**: SVM 모델을 활용해 그룹 쌍을 분류한 결과 75~80% 수준의 정확도를 달성하여 환자의 PLE 데이터만으로도 유의미한 치매 진단 가능

국내외 연구 데이터에 대한 연관 논문 및 데이터셋 추천 에이전트 개발



2025 DATA AI 분석 경진대회 | 25.10

프로젝트 개요

- 프로젝트명: 국내외 연구 데이터에 대한 연관 논문 및 데이터셋 추천 에이전트 개발 - sLLM 기반 추천 에이전트 개발
- 목적 및 배경: KISTI DataON 또는 ScienceON 등 방대한 데이터 및 논문이 축적되는 연구데이터 폭증 시대 속, LLM의 의미 추론 및 자연어 생성 능력을 활용해 LLM 기반의 설명 가능한 추천 에이전트를 구현하고자 함.
- 3대 핵심 목표: 높은 정확도 및 신뢰성 확보, 사용자 친화적 결과 제공, 최적화된 시스템 구축

파이프라인



- LLM 기반의 의미 분석 및 후보군 생성: Qwen-14B 모델을 활용해 핵심 목표와 주요 방법론을 JSON 형태로 구조화 하여 추출 후 DataON/ScienceON API를 호출하여 후보군 확보
- 하이브리드 재정렬: 임베딩 유사도 기반으로 필터링한 후 sLLM 기반 재정렬하여 최종 순위 상위 5개 확정
- 최종 결과 제공: sLLM이 구체적인 연관성을 2~3문장으로 설명 & 강추/추천/참고 등급 부여

Case Study

- Input: 인체 근골격계 기반 고정밀 의료영상/이미지 데이터
- 생성된 키워드: 'Medical Imaging', 'Digital Twin', 'Personalized Medicine', 'AI in Healthcare', 'Healthcare Data Analysis'
- 추천 결과

구분	제목	추천 사유	점수
Paper	초고속 정보통신망을 통한 3차원 영상 정보의 가상현실 관리에 관한 연구	두 데이터는 3차원 영상 정보의 처리 및 활용이라는 핵심적인 공통 점을 가진다. ...	66.29 (추천)
Paper	딥러닝 기반 의료영상 분석을 위한 데이터 증강 기법	모두 의료 영상 분석을 위한 딥러닝 기술의 핵심 자원이라는 공통 점을 가집니다. 입력 데이터 '의료영상데이터' 는 ...	66.07 (추천)
Dataset	Survey Data on CNN, Medical Imaging, and Colon Cancer Publication in IEEE, Science Direct, and Springer Nature	모두 의료 영상 분석, 특히 대장암 진단에 활용되는 딥러닝 기술 (CNN)의 연구 동향을 주제로 하고 ...	48.86 (참고)

주요 결과 & 한계점

- 주요 정량적 지표 결과

지표	점수
nDCG@10	0.9265
MRR@10	0.9700
Recall@5	1.0000
Precision@5	0.8680
F1@5	0.9214

- ✓ LLM과 임베딩 모델을 결합한 하이브리드 추천 시스템 개발
- ✓ DataON 데이터의 맥락을 깊이 있게 이해하고 관련 논문과 데이터셋을 높은 정확도로 추천
- ✓ 높은 순위 일관성과 완전한 탐지 성능(Recall 1.0)을 보임
- ✓ 그러나, LLM Judge 평가 시 편향 분석 및 결과 교차 검증체계 도입 필요
- ✓ 또한 LLM Judge 기반 검증의 실제 시스템 반영 시 활용성, 운영 실용성 대비 필요


프로젝트 개요

- 프로젝트명: LG Aimers 7th with D&O - 곤지암 리조트 식음업장 메뉴 수요예측
- 목적 및 배경: 일·업장·메뉴 단위의 수요를 정확히 예측하여 재고, 인력 운영, 혼잡도를 안정화하고 운영과 손익을 개선하기 위함.
- 핵심 원칙: 데이터 누수를 방지하기 위해 시간 순서를 엄격히 유지하고, 판매량이 0이거나 적은 희소 데이터에 대한 안정화 규칙을 적용해 변동성을 완충함.


파이프라인 & 모델

- 고유 ID 정규화 및 날짜순 정렬을 통해 시계열 데이터의 기본 정합성 확보 & 요일 및 월의 주기성, 주말/연휴 여부 등 핵심 파생변수 생성
- 시계열 처리에 강한 Global TCN을 활용하여, 7일치를 한 번에 예측하는 모델(MIMO)과 1일씩 순차 예측하는 모델(Recursive)을 병렬로 학습
- SMAPE를 최소화하기 위해 MIMO와 Recursive 예측값을 결합할 요일별 최적의 가중치 탐색
- 최종 예측 시 두 모델의 결과물을 가중평균하여 예측의 안정성과 정확도를 극대화함.

[전체 파이프라인]



[모델 설계]



구조
TCN 4층 · 채널 128 · 커널 3 · 드롭아웃 0.2 · Softplus 헤드(비음수 보장)

입력
28일 컨텍스트(판매 1 + 캘린더 피쳐 6개) + 아이템 임베딩(EMB 32)

왜 TCN?
주기성/단기추세를 짧은 폭백으로 안정적으로 포착, 파라미터 수 대비 과적합 리스크 낮음

본 구현은 WeightNorm 미사용

두 트랙 병행

- MIMO (H=7): 7일을 한 번에 예측
- Recursive (H=1): 1일씩 7회 전개 + Unroll 보조손실 + Teacher Forcing(0.5) → 장기 예측 안정화

학습세팅

- Loss: SMAPE(타겟 ≈ 0 마스크 옵션)
- Optimizer: AdamW(LR 1e-3) · Batch 1024 · Epoch 50
- Early Stopping(10) · Grad Clip 1.0 · Seed 고정 · Cosine LR

결과 & 한계점

- ✓ 주최 측이 제공한 베이스라인 모델의 예측 오차(SMAPE) 2.0 대비, 본 팀이 개발한 파이프라인은 0.48 수준까지 오차 대폭 축소
- ✓ 총 817개 참가 팀 중 최종 48위를 기록하여 상위 6%에 진입하는 성과를 거둠.
- ✓ MIMO 모델과 Recursive 모델을 별도의 트랙으로 학습시키고, 요일별 양상을 가중치까지 세밀하게 탐색한 전략이 오히려 데이터셋에 과도하게 최적화되는 결과를 초래함.
- ✓ 단순히 검증 지표를 높이기 위한 복잡한 양상을 기법보다, 변동성이 큰 새로운 데이터에도 안정적으로 대응할 수 있는 단순하고 범용적인 모델 구조가 더 유리할 수 있다는 실무적 교훈을 얻음.
- ✓ 향후 유사한 시계열 예측 문제 수행 시, 통합적인 블렌딩 기법을 적용하여 모델의 범용성과 실무 적용 가능성을 높이고자 함.